



Árboles de Decisión en Machine Learning: *Decision Tree*

Canela Lupercio Paola
paocanelalu@ciencias.unam.mx

7 de octubre de 2026

Profesores:
Dr. Chairez Veloz José Eduardo
Dr. Villarreal López Alejandro
Ávila López Misael Saúl



1. Descripción
2. Fundamento matemático
3. Representación gráfica
4. Referencias



1. Descripción

2. Fundamento matemático

3. Representación gráfica


4. Referencias



Definición

Modelo de **aprendizaje supervisado** que toma decisiones haciendo una serie de preguntas de sí o no sobre los datos [1, 2].

- Cada respuesta descarta posibilidades.
- Nadie le da las preguntas, el modelo las descubre a partir de los datos.




- **Nodo raíz:** la primera pregunta.
- **Nodos internos:** preguntas intermedias.
- **Ramas:** las respuestas que conectan los nodos.
- **Hojas:** ya no hay preguntas; aquí se da la **predicción**.

Se dibuja “al revés”: la raíz arriba y las hojas abajo [4].

¿Cómo hace una predicción?



Un dato nuevo entra por la raíz y **baja respondiendo cada pregunta** hasta llegar a una hoja. A este recorrido se le llama *inference path* [2].



Ejemplo

Llega una flor con pétalo de **1.4 cm**.

¿ $1.4 \leq 2.45$? $\Rightarrow$ **sí**

Predicción: **Setosa**



El mismo método sirve para dos tipos de problemas. La diferencia está en lo que entrega la hoja [4]:

Clasificación

La hoja da una **categoría**: la más común entre los ejemplos que llegaron ahí.

Ej.: la especie de una flor.

Regresión

La hoja da un **número**: el promedio de los ejemplos que llegaron ahí.

Ej.: el salario de un jugador.



1. Descripción
- 2. Fundamento matemático**
3. Representación gráfica
4. Referencias



El árbol divide los datos en **grupos** donde los ejemplos se parecen mucho entre sí [4].

Grupo puro

Un buen grupo es puro cuando casi todos sus ejemplos son de la misma clase.

Cada pregunta es un **corte** que separa los datos en dos grupos **más puros** que el original.

¿Cómo elige las preguntas?



Probar todos los árboles posibles es imposible: es un problema **NP-completo** [1]. Por eso se usa una estrategia más simple [4]:

- 1 Empieza con **todos los datos** en la raíz.
- 2 Prueba muchas preguntas y se queda con la que **mejor separa** los datos.
- 3 **Repite** lo mismo dentro de cada grupo nuevo.

Es **codicioso** (*greedy*): en cada paso elige lo mejor en ese momento, sin planear los pasos siguientes.

¿Qué tan “revuelto” está un grupo?



Se mide con la **impureza**. La más usada es el **índice de Gini** [1]:

$$G = 1 - \sum_k p_k^2 \quad (1)$$

p_k : proporción de la clase k en el grupo.

- Grupo **puro** $\Rightarrow G = 0$. Más mezclado $\Rightarrow G$ más grande.
- Interpretación: probabilidad de equivocarse al etiquetar al azar un elemento del grupo [3].
- La entropía, que mide el “desorden”; da resultados muy parecidos [4].

¿Cuál es la mejor pregunta?



La que más reduce el desorden. Para cada pregunta posible se compara el desorden **antes** y **después** del corte:

$$\text{Ganancia} = \text{impureza antes} - \text{impureza después} \quad (2)$$

- “Después” es el promedio de los dos grupos, ponderado por su tamaño.
- Con entropía se llama ganancia de información [1, 3].

El árbol elige la pregunta con la **mayor ganancia**.



Si el árbol pregunta sin límite, **memoriza** los datos de entrenamiento (incluido su ruido) y falla con datos nuevos: esto es el **sobreajuste** [1, 2].

Limitar el crecimiento

Fijar una **profundidad máxima** o un **mínimo de ejemplos** por hoja.

Podar


Dejar crecer el árbol y luego **cortar las ramas** que no aportan. [5, 4].




1. Descripción
2. Fundamento matemático
- 3. Representación gráfica**
4. Referencias



La forma más intuitiva: cada caja es una **pregunta** y cada hoja una **especie**.





- Con dos variables, cada pregunta es una **línea recta paralela a un eje**.
- El plano queda dividido en **rectángulos**.
- Cada rectángulo = **una hoja** del árbol [4].

Por eso sus fronteras son “escalonadas”, a diferencia de un modelo lineal, que traza una sola línea diagonal [4].



En pocas palabras

Un árbol de decisión aprende **preguntas de sí o no** que separan los datos en grupos cada vez **más puros**.

- **Ventaja:** es fácil de entender y de visualizar [1, 3].
- **Cuidado:** hay que controlar su tamaño para que no memorice los datos.



1. Descripción
2. Fundamento matemático
3. Representación gráfica
- 4. Referencias**



scikit-learn developers, “1.10. Decision Trees,” *scikit-learn User Guide*.
<https://scikit-learn.org/stable/modules/tree.html>



Google for Developers, “Decision Forests,” *Machine Learning course*.
<https://developers.google.com/machine-learning/decision-forests>



E. Kavlakoglu, “What is a Decision Tree?,” *IBM Think*, 2021.
<https://www.ibm.com/think/topics/decision-trees>



G. James, D. Witten, T. Hastie, R. Tibshirani y J. Taylor, *An Introduction to Statistical Learning: with Applications in Python*. Springer, 2023. Cap. 8.



scikit-learn developers, “DecisionTreeClassifier,” *scikit-learn API Reference*.
<https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>



Árboles de Decisión en Machine Learning: *Decision Tree*

Canela Lupercio Paola
paocanelalu@ciencias.unam.mx

7 de octubre de 2026

Profesores:
Dr. Chairez Veloz José Eduardo
Dr. Villarreal López Alejandro
Ávila López Misael Saúl